Aprendizado Não-Supervisionado

Prof. Luan Garcia

Trabalho Avaliativo

Agrupamento de Dados com Partições Desconhecidas

Objetivo:

Neste trabalho, cada aluno deverá escolher um conjunto de dados e realizar uma análise de clustering, comparando diferentes algoritmos de agrupamento e avaliando os resultados por meio de índices de qualidade. O código e toda a discussão devem estar organizados em um Jupyter Notebook, e os resultados devem ser apresentados em aula ao professor e à turma.

Escolha do Dataset:

Os alunos são responsáveis por escolher um conjunto de dados adequado à tarefa de clustering. É recomendável que os dados sejam multivariados e não rotulados. A escolha deve **necessariamente** ser previamente validada com o professor e o dataset também deve ser explicado na apresentação.

A escolha do dataset reflete na análise que pode ser realizada, o que consequentemente reflete na nota do trabalho. Datasets simplórios só permitem análises simplórias.

Sugestão para busca de datasets: kaggle

Tarefas:

1.Aplicação dos Algoritmos de Clustering:

Pelo menos dois tipos de abordagens de algoritmos de clustering distintos. Por exemplo, k-means e densidade, ou hierárquico e por densidade. Não necessariamente precisam ser algoritmos que vimos em sala de aula, mas caso seja escolhido um algoritmo diferente, é necessário explicar seu funcionamento para a turma.

2. Avaliação dos resultados

A avaliação deve abranger critérios interno e relativos. Por exemplo, utilize os índices de Variância Intra-cluster, Conectividade e Silhueta para avaliar a qualidade dos agrupamentos encontrados por cada um dos algoritmos e depois para comparar os melhores resultados entre os diferentes algoritmos. Outros índices podem ser utilizados, desde que devidamente justificados e explicados.

3. Conclusão:

Discuta as limitações dos métodos e métricas aplicadas. O resultado foi satisfatório? Qual algoritmo você considera que obteve o melhor resultado e por quê? Os agrupamentos encontrados fazem sentido para o contexto dos dados?

Entrega:

Apresentação em Aula. Cada aluno deverá apresentar em até 15 minutos os principais pontos do trabalho, incluindo: escolha e descrição do dataset, algoritmos escolhidos, comparativo entre algoritmos, métricas utilizadas, interpretação dos clusters encontrados e conclusões.

Jupyter Notebook contendo o código utilizado para realizar os agrupamentos e células markdown contendo uma discussão sobre as escolhas realizadas e os resultados encontrados.